

数值计算复习笔记

徐大鹏

2017年6月14日

1 概论

提到的考点：1.1 – 1.3.9 适定的、不适定的；误差来源和表示、条件数；机器精度；舍入误差：大数吃小数、抵消。

条件数：解的相对变化与输入数据相对变化的比值。

$$\text{condition number} = \frac{\left| \frac{(\hat{y}-y)}{y} \right|}{\left| \frac{(\hat{x}-x)}{x} \right|} = \left| \frac{\frac{\Delta y}{y}}{\frac{\Delta x}{x}} \right| = \left| \frac{x \cdot \Delta y}{y \cdot \Delta x} \right|$$

条件数刻画了问题的病态性，病态性的另一种说法是敏感性。也就是如果输入数据只变化了一点点，那么输出数据会变化多少。这个概念和在数学建模的灵敏性分析中使用的概念相一致。如果敏感性越强，意味着输入数据变化相同的范围，输出数据会有更大的变化，在上述定义式中，也就是分子更大，这样的结果就是条件数更大。

使用导数的概念可以得到条件数在某一点 x 的近似表示。

$$\text{condition number} = \left| \frac{x}{y} \cdot \frac{\Delta y}{\Delta x} \right| \stackrel{x \rightarrow \infty}{=} \left| \frac{x}{y} \cdot y'(x) \right| \stackrel{y=f(x)}{=} \left| \frac{x \cdot f'(x)}{f(x)} \right|$$

这种表示形式的最大好处在于，只和自变量 x 相关，便于分析和计算。上面这种形式的条件数是最常用的计算形式，必须熟记。

对于反函数 $x = f^{-1}(y) = g(y)$ 而言，它的条件数是

$$\text{condition number} \stackrel{y \rightarrow \infty}{=} \left| \frac{y \cdot g'(y)}{x} \right| = \left| \frac{y \cdot \frac{1}{f'(x)}}{x} \right| = \left| \frac{y}{x \cdot f'(x)} \right| = \left| \frac{f(x)}{x \cdot f'(x)} \right|$$

正好就是原函数的条件数的倒数。

条件数的概念会和第二章线性方程组、第五章非线性方程组有联系。
当 x 或 y 为零时，无法计算条件数，只能使用绝对条件数代替。

$$\text{absolute condition number} = \left| \frac{\Delta y}{\Delta x} \right|$$

浮点系统可以使用四个参数完备地表示：基数 β 、精度 p 、 L 、 U 。它们的含义是什么？

$$x = \pm \left(\sum_{i=0}^p \frac{d_i}{\beta^i} \right) \beta^E$$

正规化浮点系统的下溢限

$$\text{UFL} = \beta^L$$

上溢限

$$\text{OFL} = \beta^{U+1}(1 - \beta^{-p})$$

正规化浮点数的总个数

$$2(\beta - 1)\beta^{p-1}(U - L + 1) + 1$$

截断舍入的机器精度

$$\epsilon_{mach} = \beta^{1-p}$$

最近舍入的机器精度

$$\epsilon_{mach} = \frac{1}{2}\beta^{1-p}$$

机器精度的含义是什么？

舍入误差分析的标准模型：

$$\text{fl}(x \text{ op } y) = (x \text{ op } y)(1 + \delta)$$

其中 op 可以是加、减、乘、除中的任意一种，相对扰动 $|\delta| \leq \epsilon_{mach}$ 。

2 线性方程组

提到的考点：2.3 — 2.4.8 范数、性质、条件数、误差限、影响因素、残差；高斯消去法、LU分解。2.5 特殊线性方程组的解法：对称正定方程组的求解、带状方程组的求解。2.6 迭代法（参考第11章）：雅克比方法、高斯-赛德尔方法、SOR方法。

2.1 回顾：赋范线性空间

向量的 p -范数：

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

注意表达式里，每一个分量 x_i 都取了绝对值。

矩阵范数：定义 $m \times n$ 的矩阵 \mathbf{A} 的（向量诱导）范数是

$$\|\mathbf{A}\| = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}$$

使用向量1-范数、 ∞ -范数的结果不太容易推导，直接记住形式：

$$\|\mathbf{A}\|_1 = \max_j \sum_{i=1}^m |a_{ij}|$$

$$\|\mathbf{A}\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$$

一个是按行求和，一个是按列求和。

2.2 矩阵的条件数、误差限、残差

矩阵条件数的性质：

1. 对任意 \mathbf{A} ， $\text{cond}(\mathbf{A}) \geq 1$ 。
不会证。
2. 对任意 \mathbf{A} 及非零标量 γ ， $\text{cond}(\gamma\mathbf{A}) = \text{cond}(\mathbf{A})$ 。
因为 $\mathbf{I} = (\gamma\mathbf{A}) \cdot (\gamma\mathbf{A})^{-1} = (\gamma\mathbf{A}) \cdot (\gamma^{-1}\mathbf{A}^{-1})$,

$$\begin{aligned} \text{cond}(\gamma\mathbf{A}) &= \|\gamma\mathbf{A}\| \cdot \|\gamma^{-1}\mathbf{A}^{-1}\| \\ &= |\gamma| \cdot \|\mathbf{A}\| \cdot |\gamma^{-1}| \cdot \|\mathbf{A}^{-1}\| \\ &= \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\| = \text{cond}(\mathbf{A}) \end{aligned}$$

3. 对任意对角阵， $\mathbf{D} = \text{diag}(d_i)$ ， $\text{cond}(\mathbf{D}) = \frac{\max_i |d_i|}{\min_i |d_i|}$ 。
证：显然。

条件数 $\text{cond}(\mathbf{A})$ 刻画了矩阵接近奇异的程度。行列式 $\det(\mathbf{A})$ 刻画了矩阵是否是奇异的。

第2.3.4节主要讲了求解线性方程组的误差限表示、误差限和什么相关，以及如何推导误差限的问题。推导得到了两个主要结论。第一个是，右端向量带有扰动的方程组 $\mathbf{A}(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}$ 的解的估计式是

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \text{cond}(\mathbf{A}) \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}$$

第二个是，矩阵 \mathbf{A} 的元素带有扰动的方程组 $(\mathbf{A} + \mathbf{E})(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b}$ 的解的估计式是

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x} + \Delta\mathbf{x}\|} \leq \text{cond}(\mathbf{A}) \frac{\|\mathbf{E}\|}{\|\mathbf{A}\|}$$

注意直接使用不等式推得的第二个结论中，左边分母上是带扰动的输入 $\mathbf{x} + \Delta\mathbf{x}$ 。

使用更精确的方法改进第二个结论？然后可以得到最终的结论：

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \text{cond}(\mathbf{A}) \left(\frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} + \frac{\|\mathbf{E}\|}{\|\mathbf{A}\|} \right)$$

上式左侧的分式是向前误差，右侧的分式是向后误差。条件数是输出误差对输入误差的一个估计。一个输入数据的误差输入数据的误差就是数据传播误差。浮点系统的数据传播误差的大小由机器精度 ϵ_{mach} 决定。可以将上式写成这种形式

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \lesssim \text{cond}(\mathbf{A}) \epsilon_{mach}$$

矩阵条件数 $\text{cond}(\mathbf{A})$ 太大的原因：

1. 矩阵本身是接近奇异的，也就是行向量之间接近线性相关；
2. 观测的数据相差太大，比如某个列向量大了很多个数量级

残差：

$$\mathbf{r} = \mathbf{b} - \mathbf{A}\hat{\mathbf{x}}$$

相对残差：

$$\frac{\|\mathbf{r}\|}{\|\mathbf{A}\| \cdot \|\hat{\mathbf{x}}\|}$$

稳定算法产生的相对残差总是很小。

2.3 一般方法：Gauss消去和LU分解

线性方程组的求解：相互等价的两种算法，Gauss消去法和LU分解。这里，我们构造了一个初等消去阵

$$\mathbf{M}_k = \mathbf{I} - \mathbf{m}\mathbf{e}_k^T$$

$$M_k a = \begin{bmatrix} 1 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & 0 & \cdots & 0 \\ 0 & \cdots & -m_{k+1} & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & -m_n & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ \vdots \\ a_k \\ a_{k+1} \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} a_1 \\ \vdots \\ a_k \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

，其中

$$m = (0, \cdots, 0, m_{k+1}, \cdots, m_n)$$

考虑到 $m_i = a_i/a_k$ ，上式可写作

$$m = (0, \cdots, 0, \frac{a_{k+1}}{a_k}, \cdots, \frac{a_n}{a_k})$$

M_k 是一个单位下三角矩阵，然后后面就很显然了，果然没什么好推的。

选主元：每次循环时选择最大的元素作为主元，因为主元 a_k 出现在 $m_i = a_i/a_k$ 的分母上。如果 a_k 比较小，会产生一个非常大的乘数 m_i ，从而造成大数吃小数的（抵消）问题，导致误差。选主元的结果是在 A 上乘以了一个排列矩阵 P ，使

$$PA = LU$$

这样，求解 $Ax = b$ 的问题等价转化为求解 $PAx = Pb$ 的问题。特别注意，排列阵 P 具有性质

$$P^{-1} = P^T$$

另外，这个性质实际上说明排列阵 P 是一个正交矩阵。

高斯-若当（Gauss-Jordan）消去法：这种方法的区别在于，开始于

$$\left[A \mid I \right]$$

但是行化简的方式，是将非对角线上的元素一次消去，是一种彻底的消元法。消元后，乘以一个对角矩阵将左侧矩阵的对角元素化为全1。最终得到的结果是

$$\left[I \mid A^{-1} \right]$$

这种方法更适合于求出逆矩阵 A^{-1} 。

2.4 特殊方程组：Cholesky分解和简化的LU分解

对称正定方程组：如果 \mathbf{A} 是对称正定的，那么 $\mathbf{A} = \mathbf{L}\mathbf{L}^T > 0$
楚列斯基分解的特点：

1. 所需计算的 n 个平方根都是正数
2. 不需要选主元就可以保证数值稳定
3. \mathbf{A} 是对称正定的，上三角部分的元素用不到而且无需存储
4. 仅仅需要做 $\frac{n^3}{6}$ 次乘法

Cholesky分解和LU分解的区别：

1. Cholesky分解得到的下三角矩阵 \mathbf{L} 不一定是单位下三角矩阵。
2. Cholesky分解不需要选主元
3. Cholesky分解需要计算平方根

最后，带状方程组的求解，是LU分解求解一般方程组的一个特殊情况。

3 线性最小二乘

提到的考点：正规方程组、增广方程组、QR分解（Householder变换、Givens旋转、Gram-Schmidt正交化方法）、奇异值分解。

3.1 目标、相关概念、惟一性

目标是极小化残差向量 $\mathbf{r} = \mathbf{b} - \mathbf{A}\mathbf{x}$ 。过程中最好选择2-范数，因为它与内积有关，具有正交性、光滑性、严格凸性。

一个一维函数 f 是**严格凸的**，如果这个函数在区间 (x, y) 上满足

$$\forall t \in (0, 1), \quad f(tx + (1-t)y) < tf(x) + (1-t)f(y)$$

范德蒙矩阵是列向量的每个分量上呈现等比关系的矩阵

$$V = \begin{bmatrix} 1 & \alpha_1 & \alpha_1^2 & \cdots & \alpha_1^{n-1} \\ 1 & \alpha_2 & \alpha_2^2 & \cdots & \alpha_2^{n-1} \\ 1 & \alpha_3 & \alpha_3^2 & \cdots & \alpha_3^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \alpha_m & \alpha_m^2 & \cdots & \alpha_m^{n-1} \end{bmatrix}$$

它的每一个元素是

$$V_{i,j} = \alpha_i^{j-1}$$

当它是 n 阶方阵时，行列式为

$$\det(V) = \prod_{1 \leq i < j \leq n} (\alpha_j - \alpha_i)$$

线性最小二乘的解唯一的条件是，矩阵 \mathbf{A} 是列满秩的。

3.2 正规方程组

如果 \mathbf{A} 是列满秩的，则 $n \times n$ 正定对称正规方程组 $\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b}$ 与 $m \times n$ 最小二乘问题 $\mathbf{A} \mathbf{x} \cong \mathbf{b}$ 同解。使用Cholesky分解求解这个线性方程组的解。

正规方程组的敏感性很强，因为叉积矩阵 $\mathbf{A}^T \mathbf{A}$ 的条件数是原矩阵条件数的平方。

3.3 QR分解

正交矩阵的特点：

1. 不会变化向量的2-范数。
2. $Q Q^T = Q Q^{-1} = I$

课本先说了QR分解是什么，后说了如何做QR分解。QR分解的核心在于，对于每个 $m \times n$ 矩阵 \mathbf{A} 能找到一个 $m \times m$ 的正交矩阵 \mathbf{Q} ，使得

$$\mathbf{A} = \mathbf{Q} \begin{bmatrix} \mathbf{R} \\ \mathbf{0} \end{bmatrix}$$

至于这个正交矩阵 \mathbf{Q} 是如何找到的，则是通过House-Hold变换、Givens旋转、Gram-Schmidt正交化等算法实现的。课本上所做的一个证明是，证明

$$\mathbf{Q} \begin{bmatrix} \mathbf{R} \\ \mathbf{0} \end{bmatrix} \mathbf{x} \cong \mathbf{b}$$

和

$$\begin{bmatrix} \mathbf{R} \\ \mathbf{0} \end{bmatrix} \mathbf{x} \cong \mathbf{Q}^T \mathbf{b}$$

是同解的。这样，我们只需验证House-Hold变换等算法是实现了QR分解的

$$A = Q \begin{bmatrix} R \\ 0 \end{bmatrix}$$

就能说明算法能够正确求解出线性最小二乘了。

3.4 Householder变换

Householder变换：通过反射变换，把向量映射到坐标轴上，实现消元。课本上先讨论了特殊形式，我在这里整理的是House-Hold变换的一般形式。变换矩阵 H 的形式是

$$H = I - 2 \frac{vv^T}{v^T v}$$

在QR分解中，我们最终的目标是得到一个上三角矩阵 R 。现在考虑每一个列向量是如何使用Householder变换消元的。对于一个 m 维列向量 a ，考虑分块

$$a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}$$

其中 a_1 是 $k-1$ 维向量($1 \leq k < m$)。我们的任务是什么呢？是要做QR分解，是要确定一个向量 v ，它能够将

$$H(a) : \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} \mapsto \begin{bmatrix} a_1 \\ 0 \end{bmatrix} + \alpha e_k$$

有了这个目标，我们看看如何确定那个 v 。确定了 v 也就确定了 H 。一方面，

$$\begin{aligned} Ha &= \left(I - 2 \frac{vv^T}{v^T v} \right) a \\ &= a - 2v \frac{v^T a}{v^T v} \\ &= \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} - 2v \frac{v^T a}{v^T v} \end{aligned}$$

另一方面，

$$H(a) = Ha = \begin{bmatrix} a_1 \\ 0 \end{bmatrix} + \alpha e_k$$

于是就有，

$$\begin{bmatrix} a_1 \\ a_2 \end{bmatrix} - 2v \frac{v^T a}{v^T v} = \begin{bmatrix} a_1 \\ 0 \end{bmatrix} + \alpha e_k$$

$$\begin{bmatrix} \mathbf{0} \\ \mathbf{a}_2 \end{bmatrix} - \alpha \mathbf{e}_k = 2\mathbf{v} \frac{\mathbf{v}^T \mathbf{a}}{\mathbf{v}^T \mathbf{v}}$$

$$\mathbf{v} = \frac{\mathbf{v}^T \mathbf{v}}{2\mathbf{v}^T \mathbf{a}} \left(\begin{bmatrix} \mathbf{0} \\ \mathbf{a}_2 \end{bmatrix} - \alpha \mathbf{e}_k \right)$$

为了计算简便，消去上式右端的标量系数是可行的。因为

$$\begin{aligned} \mathbf{H} &= \mathbf{I} - 2 \frac{(\beta \mathbf{v})(\beta \mathbf{v})^T}{(\beta \mathbf{v})^T (\beta \mathbf{v})} \\ &= \mathbf{I} - 2 \frac{\beta^2 \mathbf{v} \mathbf{v}^T}{\beta^2 \mathbf{v}^T \mathbf{v}} \\ &= \mathbf{I} - 2 \frac{\mathbf{v} \mathbf{v}^T}{\mathbf{v}^T \mathbf{v}} \end{aligned}$$

所以 \mathbf{v} 的标量系数在 \mathbf{H} 的计算过程中会被消去，没有影响。这就得到了要取的 \mathbf{v} ：

$$\mathbf{v} = \begin{bmatrix} \mathbf{0} \\ \mathbf{a}_2 \end{bmatrix} - \alpha \mathbf{e}_k$$

其中

$$\alpha = -\text{sgn}(a_k) \|\mathbf{a}_2\|_2$$

但是，这里的 α 为什么这么取值呢？ $|\alpha| = \|\mathbf{a}_2\|_2$ 的依据是什么呢？对于任意向量 \mathbf{a} ，正交矩阵 \mathbf{H} 作用于 \mathbf{a} 得到的线性映射 $\mathbf{H}(\mathbf{a})$ 有着性质

$$\|\mathbf{a}\|_2 = \|\mathbf{H}\mathbf{a}\|_2$$

对于一个具体的向量

$$\mathbf{a} = \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \end{bmatrix}$$

根据上面的讨论，如果将线性映射的结果表示成

$$\mathbf{H}(\mathbf{a}) = \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{0} \end{bmatrix} + \alpha \mathbf{e}_k$$

那么它一定满足性质

$$\left\| \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \end{bmatrix} \right\| = \left\| \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{0} \end{bmatrix} + \alpha \mathbf{e}_k \right\|$$

根据勾股定理,

$$\left\| \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \end{bmatrix} \right\|_2^2 = \|\mathbf{a}_1\|_2^2 + \|\mathbf{a}_2\|_2^2$$

$$\left\| \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{0} \end{bmatrix} + \alpha \mathbf{e}_k \right\|_2^2 = \|\mathbf{a}_1\|_2^2 + \alpha^2$$

因此

$$\alpha^2 = \|\mathbf{a}_2\|_2^2$$

$$|\alpha| = \|\mathbf{a}_2\|$$

4 非线性方程组

提到的考点: 5.1, 5.4 — 5.5.5: 收敛速度、收敛性; 二分法、牛顿法、反二次方法。迭代收敛准则。例题5.9

4.1 收敛速度和判停准则

第 k 步迭代的绝对误差是 $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$ 。考虑式子

$$\lim_{k \rightarrow \infty} \frac{\|\mathbf{e}_{k+1}\|}{\|\mathbf{e}_k\|^r} = C$$

其中, C 是一个大于零的有限常数, r 为迭代法的收敛速度。

两种判停准则:

1. 限定残差:

$$\|f(\mathbf{x}_k)\| < \epsilon$$

2. 限定相对误差:

$$\frac{\|\mathbf{x}_{k+1} - \mathbf{x}_k\|}{\max\{\|\mathbf{x}_k\|, \mathbf{1}\}} < \epsilon$$

4.2 二分法

二分法使用的中点计算方式是

$$m = a + \frac{b - a}{2}$$

判断收缩区间的条件是

$$\text{sgn}(f(a)) = \text{sgn}(f(m))$$

他们的优点是什么? (课本上有)

4.3 不动点迭代

迭代格式是

$$\mathbf{x}_{k+1} = g(\mathbf{x}_k)$$

收敛速度是线性的。迭代收敛的证明和收敛速度的证明，使用拉格朗日微分中值定理

$$\mathbf{e}_{k+1} = \mathbf{x}_{k+1} - \mathbf{x}^* = g(\mathbf{x}_k) - g(\mathbf{x}^*) = g'(\theta_k)(\mathbf{x}_k - \mathbf{x}^*) = g'(\theta_k)\mathbf{e}_k$$

如果需要证明平方收敛或者更高阶收敛，则使用泰勒中值定理。

4.4 牛顿法

迭代格式是

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \frac{f(\mathbf{x}_k)}{f'(\mathbf{x}_k)}$$

收敛速度在单根情形的收敛速度是二次的，在重根的收敛速度是线性的。

割线法略。

4.5 反二次插值

想法：改进割线法的一次函数，使用二次函数和 x 轴的交点横坐标作为下一个 x_{k+1} 。但是，二次函数可以与 x 轴没有交点，使用“反二次”就能保证一定有交点了。

为方便起见，分别记自变量 x_{k-2} 、 x_{k-1} 、 x_k 为 a 、 b 、 c ，他们对应的函数值分别为 f_a 、 f_b 、 f_c 。

构造反二次函数，即以 y 为自变量， x 为因变量，

$$x = m_0 + m_1y + m_2y^2$$

在上式中令 $y = 0$ ，可以求出曲线和 x 轴的交点

$$x_{k+1} = m_0$$

为确定 m_0 、 m_1 、 m_2 ，使用拉格朗日插值公式：

$$x(y) = a \frac{(y - f_b)(y - f_c)}{(f_a - f_b)(f_a - f_c)} + b \frac{(y - f_a)(y - f_c)}{(f_b - f_a)(f_b - f_c)} + c \frac{(y - f_a)(y - f_b)}{(f_c - f_a)(f_c - f_b)}$$

取 $y = 0$ 得到

$$x(0) = a \frac{f_b f_c}{(f_a - f_b)(f_a - f_c)} + b \frac{f_a f_c}{(f_b - f_a)(f_b - f_c)} + c \frac{f_a f_b}{(f_c - f_a)(f_c - f_b)}$$

5 插值

提到的考点：7.3 三种基函数：单项式、拉格朗日、牛顿。7.3.1 — 7.3.3, 7.3.5 余项定理。7.4.2 三次样条。例题7.6

5.1 牛顿多项式插值

对给定的数据点集 (t_j, y_j) 牛顿基函数

$$\pi_j(t) = \prod_{k=1}^{j-1} (t - t_k), \quad j = 1, \dots, n$$

对应的插值多项式

$$p_{n-1}(t) = \sum_{j=1}^n x_j \pi_j(t) = \sum_{j=1}^n \left[x_j \prod_{k=1}^{j-1} (t - t_k) \right]$$

为了求这个多项式，对应的基底矩阵 \mathbf{A} 是

$$\begin{bmatrix} 1 & & & & 0 \\ 1 & t_1 - t_0 & & & \\ 1 & t_2 - t_0 & (t_2 - t_0)(t_2 - t_1) & & \\ \vdots & \vdots & & \ddots & \\ 1 & t_n - t_0 & \dots & \dots & \prod_{j=0}^{n-1} (t_n - t_j) \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}$$

这是一个下三角矩阵，每一个 x_j 由当前行和之前的所有行确定。这说明，当新增一个数据点 t_{n+1}, y_{n+1} 时，可以直接确定系数 x_{n+1} 的值，并且在 p_{n-1} 中增加一项

$$x_{n+1} = \frac{y_{n+1} - p_n(t_{n+1})}{\pi_{n+1}(t_{n+1})} = \frac{y_{n+1} - p_n(t_{n+1})}{\prod_{k=1}^n (t_{n+1} - t_k)}$$

就可以得到 p_n 。

6 积分和微分

提到的考点：待定系数法。8.3 牛顿科特斯方法、高斯方法。简单求积公式构造出复杂的求积公式。8.6 差分公式和推导。积分：代数精度、验证法确定。